

# 参数估计

## 大数律和中心极限定理

### 强大数律

**记号：**若 $P(A) = 1$ ，则记 $A$  a.s.，即 $A$ 几乎一定（almost surely）会发生。

如果 $X_i$ 是独立同分布的随机变量，且 $\mu = EX_1$ ，则

$$\lim_{n \rightarrow \infty} \overline{X_n} = \mu \text{ a.s.}$$

因为概率等于1的事件在实际中必然发生，所以在强大数律中，如果用 $x_n$ 表示 $X_n$ 的观测值，则有

$$\lim_{n \rightarrow \infty} \frac{x_1 + x_2 + \cdots + x_n}{n} = \mu.$$

因为强大数律的数学证明并不需要概率的频率定义，所以它从理论上保证了概率的频率定义是正确的。

**利用强大数律的关键是构造独立同分布的一组随机变量。**

### 弱大数律

#### 依概率收敛

设 $U, U_1, U_2, \cdots$ 是随机变量。如果对任何 $\varepsilon > 0$ ， $\lim_{n \rightarrow \infty} P(|U_n - U| \geq \varepsilon) = 0$ ，则称 $U_n$ 依概率收敛到 $U$ ，记做 $U_n \xrightarrow{P} U$ 。

#### 切比雪夫不等式

随机变量 $X$ 的数学期望是 $\mu$ ，方差是 $\sigma^2$ ，则对常数 $\varepsilon > 0$ ，有

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

### 弱大数律

设随机变量 $X_1, X_2, \cdots$ 独立同分布， $\mu = EX_1$ ，则对任何 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \varepsilon) = 0$$

#### 对于强大数律和弱大数律的理解

设甲某是一位新的专职司机，用 $U_n$ 表示他在第 $n$ 个工作日的交通事故造成的损失。因为他的开车经验在不断提高，所以随着时间的推移，他的 $U_n$ 会向老司机的 $U = 0$ 收敛。如果 $U_n \xrightarrow{P} U$ ，则 $n \rightarrow \infty$ 时，我们只能得到

$$P(U_n \geq \varepsilon) = P(|U_n - U| \geq \varepsilon) \rightarrow 0$$

所以对任意大的 $n$ ，都不能保证 $P(U_n \geq \varepsilon) = 0$ 。也就是说，无论有多长的开车经验，这位新司机因交通事故造成较大损失的概率都是正数，从而都有可能造成较大的损失。用 $u_n$ 表示 $U_n$ 的观测值。如果 $U_n \rightarrow U$  a.s.，则实际中有 $u_n \rightarrow 0$ 。说明存在 $n_0$ ，使得 $n \geq n_0$ 时， $u_n < \varepsilon$ 。也就是说，从某天开始，这位新司机就再也不会发生有较大损失的交通事故了。

## 中心极限定理

中心极限定理研究的是当 $n$ 较大时，随机变量的部分和 $S_n = \sum X_j$ 的概率分布问题。实验表明，独立同分布随机变量和的分布近似于正态分布，这就是将要介绍的中心极限定理。

设随机变量 $X_1, X_2, \cdots$ 独立同分布， $EX_1 = \mu, \text{Var}(X_1) = \sigma^2 > 0$ 。用 $S_n = \sum_{j=1}^n X_j$ 表示部分和，用 $Z_n = \frac{S_n - n\mu}{\sqrt{n\sigma^2}}$ 表示 $S_n$ 的标准化，用 $\Phi(x)$ 表示服从 $N(0, 1)$ 的分布函数。

在上述条件下，当 $n$ 趋于正无穷时，有

$$P(Z_n \leq x) \rightarrow \Phi(x), x \in (-\infty, \infty)$$

即 $Z_n$ 依分布收敛到 $N(0, 1)$ ，记作 $Z_n \xrightarrow{d} N(0, 1)$ 。

**推论：**在上述条件下，对较大的 $n$ ，有

$$P\left(\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \leq x\right) \approx \Phi(x), \quad P\left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq x\right) \approx \Phi(x).$$

在一些实际问题中，随机变量的方差 $\sigma^2$ 是未知的，这时可以用下面两个统计量来估计 $\sigma^2$ 。

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{j=1}^n \left(X_j - \bar{X}_n\right)^2 \text{ [or] } \hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n \left(X_j - \bar{X}_n\right)^2$$

## 参数估计（上）

### 一些术语

【总体假设】设总体含有  $N$  个个体，第  $i$  个个体是  $y_i$ 。

**总体均值：** $\mu = \frac{y_1+y_2+\cdots+y_N}{N}$ 。

**总体方差/方差：** $\sigma^2 = \frac{(y_1-\mu)^2+(y_2-\mu)^2+\cdots+(y_N-\mu)^2}{N}$ 。

**总体标准差/标准差：** $\sigma = \sqrt{\sigma^2}$ 。

**总体参数/参数：**描述总体特性的指标，包括但不限于上面提到的三者，讲到参数的时候要明确它是哪个总体的参数。

【样本假设】设总体的一个抽样有  $n$  个样本，第  $i$  个样本是  $x_i$ 。

**样本均值：** $\bar{x}$ 。

**样本方差：** $s^2 = \frac{1}{n-1} \left[ (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2 \right]$ 。

**样本标准差：** $s = \sqrt{s^2}$ 。

### 估计

估计是利用**样本**计算出对**参数**的估计值。估计不是唯一的，对相同的观测数据，不同的方法可以给出不同的估计结果。

在总体中任取一个个体  $X$ ， $X$  是随机变量， $EX = \mu$  是总体均值，这说明随机抽样是无偏的。

如果用  $X_1, X_2, \cdots, X_n$  表示依次随机抽取的样本，则样本均值  $\bar{X}$  是总体均值  $\mu$  的估计，且  $E\bar{X} = \mu$ 。

设  $\hat{\theta}$  是  $\theta$  的估计。

- (1) 如果  $E\hat{\theta} = \theta$ , 则称  $\hat{\theta}$  是  $\theta$  的无偏估计；
- (2) 如果当样本量  $n \rightarrow \infty$ ,  $\hat{\theta}$  依概率收敛到  $\theta$ ，则称  $\hat{\theta}$  是  $\theta$  的相合估计；
- (3) 如果当样本量  $n \rightarrow \infty$ ,  $\hat{\theta}$  以概率 1 收敛到  $\theta$ ，则称  $\hat{\theta}$  是  $\theta$  的强相合估计。

### 样本均值

设总体均值  $\mu = EX$  存在， $X_1, X_2, \cdots, X_n$  是总体  $X$  的样本。均值  $\mu$  的估计定义为

$$\bar{X}_n = \frac{X_1 + X_2 + \cdots + X_n}{n}$$

样本均值  $\bar{X}_n$  有如下的性质：

- (1)  $\bar{X}_n$  是  $\mu$  的无偏估计，这是因为  $E\bar{X}_n = \mu$ ；
- (2)  $\bar{X}_n$  是  $\mu$  的强相合估计，从而是相合估计。这是因为从强大数律得到

$$\lim_{n \rightarrow \infty} \bar{x}_n = \mu \text{ a.s.}$$

### 样本方差

给定总体  $X$  的样本  $X_1, X_2, \cdots, X_n$ ，用  $\hat{\mu}$  表示样本均值。总体方差  $\sigma^2 = \text{Var}(X)$  的估计由下式定义。

$$S^2 = \frac{1}{n-1} \sum_{j=1}^n \left(X_j - \hat{\mu}\right)^2$$

样本方差的性质：

- (1) 样本方差  $S^2$  是总体方差的无偏估计， $ES^2 = \frac{1}{n-1} \sum_{j=1}^n E\left(X_j - \hat{\mu}\right)^2 = \frac{n}{n-1} \cdot \frac{n-1}{n} \sigma^2 = \sigma^2$ 。

**具体证明：**取定  $j$ 。因为  $E\left(X_j - \hat{\mu}\right) = \mu - \mu = 0$ ，所以从  $X_1, X_2, \cdots, X_n$  的独立性得到

$$\begin{aligned} \mathbb{E}(X_j - \hat{\mu})^2 &= \text{Var}\left(X_j - \frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \text{Var}\left[\left(1 - \frac{1}{n}\right)X_j - \frac{1}{n} \sum_{i \neq j} X_i\right] \\ &= \left(\frac{n-1}{n}\right)^2 \sigma^2 + \frac{1}{n^2} \sum_{i \neq j} \sigma^2 \\ &= \frac{\left[\left(\frac{n-1}{n}\right)^2 + \frac{n-1}{n^2}\right] \sigma^2}{n} \\ &= \frac{n-1}{n} \sigma^2 \end{aligned}$$

(2) 样本方差  $S^2$  是总体方差  $\sigma^2$  的强相合估计。

**具体证明：**利用强大数律  $\hat{\mu} \rightarrow \mu$  a.s. 和  $\frac{1}{n-1} \sum_{j=1}^n X_j^2 \rightarrow \mathbb{E}X^2$  a.s. , 得到

$$\begin{aligned} \frac{1}{n-1} \sum_{j=1}^n (X_j - \hat{\mu})^2 &= \frac{1}{n-1} \sum_{j=1}^n (X_j^2 - 2X_j\hat{\mu} + \hat{\mu}^2) \\ &= \frac{1}{n-1} \left( \sum_{j=1}^n X_j^2 - 2n\frac{1}{n} \sum_{j=1}^n X_j\hat{\mu} + n\hat{\mu}^2 \right) \\ &= \frac{1}{n-1} \sum_{j=1}^n X_j^2 - \frac{n}{n-1} \hat{\mu}^2 \\ &\rightarrow EX^2 - \mu^2 = \sigma^2 \text{ a.s.} \end{aligned}$$

### 样本标准差

由于  $S^2$  是  $\sigma^2$  的估计，所以定义标准差  $\sigma$  的估计为

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{j=1}^n (X_j - \hat{\mu})^2}$$

称  $S$  为样本标准差。

(1) 由于  $S^2 \rightarrow \sigma^2$  a.s., 所以  $S \rightarrow \sigma$  a.s. 成立，说明  $S$  是  $\sigma$  的强相合估计。

(2) 当  $\sigma > 0$ ,  $S$  不是  $\sigma$  的无偏估计，也就是说  $ES = \sigma$  不成立。这是因为**没有不全为零的常数 $a, b$ 使得  $P(aS + b = 0) = 1$** ，所以由内积不等式得到

$$\mathbb{E}S = \mathbb{E}(S \cdot 1) < \sqrt{\mathbb{E}S^2 \cdot \mathbb{E}1^2} = \sqrt{\sigma^2} = \sigma.$$

这时称  $S$  低估了  $\sigma$ 。

因为上面三个的强相合性，如果  $x_1, x_2, \cdots, x_n$  是总体  $X$  的样本，则如下事实得到保证：

$$\lim_{n \rightarrow \infty} \bar{x}_n = \mu, \lim_{n \rightarrow \infty} s^2 = \sigma^2, \lim_{n \rightarrow \infty} s = \sigma.$$

### 样本矩

因为  $X_1^k, X_2^k, \cdots, X_n^k$  独立同分布，且和  $X^k$  同分布，所以是总体  $X^k$  的样本。并且

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

是  $\mu_k$  的估计。所以  $\hat{\mu}_k$  是  $\mu_k$  的**强相合无偏估计**。称  $\mu_k = \mathbb{E}X^k$  为  $X$  的  $k$  阶原点矩, 称  $\hat{\mu}_k$  为  $k$  阶样本 原点矩。

#### 估计的技巧

(1) 如果总体  $X$  的分布函数  $F(x; \theta)$  只有一个未知参数  $\theta$ ，则  $\mu_1 = \mathbb{E}X$  常和  $\theta$  有关。如果  $g(s)$  是已知函数，并且能从  $\mu_1 = \mathbb{E}X$  得到  $\theta = g(\mu_1)$ ，则  $\hat{\theta} = g(\hat{\mu}_1)$  是  $\theta$  的矩估计，其中  $\hat{\mu}_1$  是样本均值。

(2) 如果总体  $X$  的分布函数  $F(x; \theta_1, \theta_2)$  有 2 个未知参数  $\theta_1, \theta_2$ ，则  $\mu_1 = \mathbb{E}X$  和  $\mu_2 = \mathbb{E}X^2$  常和  $\theta_1, \theta_2$  有关。如果  $g_1(s, t), g_2(s, t)$  是已知函数，并且能从

$$\begin{cases} \mu_1 = \mathbb{E}X, \\ \mu_2 = \mathbb{E}X^2 \end{cases} \quad [\text{get}] \quad \begin{cases} \theta_1 = g_1(\mu_1, \mu_2), \\ \theta_2 = g_2(\mu_1, \mu_2), \end{cases}$$

则  $\hat{\theta}_1 = g_1(\hat{\mu}_1, \hat{\mu}_2), \hat{\theta}_2 = g_2(\hat{\mu}_1, \hat{\mu}_2)$  分别是  $\theta_1, \theta_2$  的矩估计。

# 最大似然估计

## 离散情况

设离散随机变量  $X_1, X_2, \dots, X_n$  有联合分布

$$p(x_1, x_2, \dots, x_n; \theta) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n),$$

其中  $\theta$  是未知参数, 给定观测数据  $x_1, x_2, \dots, x_n$  后, 称  $\theta$  的函数

$$L(\theta) = p(x_1, x_2, \dots, x_n; \theta)$$

为似然函数, 称  $L(\theta)$  的最大值点  $\hat{\theta}$  为  $\theta$  的最大似然估计.

许多情况下, 为了方便计算, 一般取  $l(\theta) = \ln L(\theta)$  进行最值点的求解。

## 连续情况

类似离散的情况, 此时  $P(X = x) = f(x; \theta)dx$ 。

设随机向量  $X = (X_1, X_2, \dots, X_n)$  有联合密度  $f(\boldsymbol{x}; \boldsymbol{\theta})$ , 其中  $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_m)$  是未知参数。得到  $\boldsymbol{X}$  的观测值  $\boldsymbol{x} = (x_1, x_2, \dots, x_n)$  后, 称

$$L(\boldsymbol{\theta}) = f(\boldsymbol{x}; \boldsymbol{\theta})$$

为  $\boldsymbol{\theta}$  的似然函数, 称  $L(\boldsymbol{\theta})$  的最大值点  $\hat{\boldsymbol{\theta}}$  为  $\boldsymbol{\theta}$  的最大似然估计 (MLE)。

设总体  $X$  有概率密度  $f(x; \boldsymbol{\theta})$ , 则  $X$  的样本  $X_1, X_2, \dots, X_n$  有联合密度

$$f(x_1, x_2, \dots, x_n; \boldsymbol{\theta}) = \prod_{j=1}^n f(x_j; \boldsymbol{\theta})$$

基于观测值  $\boldsymbol{x} = (x_1, x_2, \dots, x_n)$  的似然函数是

$$L(\boldsymbol{\theta}) = \prod_{j=1}^n f(x_j; \boldsymbol{\theta})$$

同样取  $l(\vec{\theta}) = \ln L(\vec{\theta})$ , 求最大值点可以通过解方程组  $\frac{\partial l(\vec{\theta})}{\partial \theta_j} = 0, j = 1, 2, \dots, m$  来获得。

这里要深刻理解, 还需要做一些题, 也可以看一下书上的例子。比如估计  $N(\mu, \sigma^2)$ , 这里  $\sigma^2$  是参数而不是  $\sigma$ , 要对  $\sigma^2$  求偏微分。