

IML 第二次作业

习题 3.2

令 $y = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}}$, $l(\boldsymbol{\beta}) = \sum_{i=1}^m \left(-y_i \boldsymbol{\beta}^\top \hat{\mathbf{x}}_i + \ln(1 + e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i}) \right)$, 这两个函数关于 \mathbf{w} 和 $\boldsymbol{\beta} = (\mathbf{w}; b)$ 是二阶可微的, 分别计算二者的 Hessian 矩阵:

$$\begin{aligned} \frac{\partial y}{\partial \boldsymbol{\omega}} &= \frac{e^{-(\boldsymbol{\omega}^\top \mathbf{x} + b)}}{\left[1 + e^{-(\boldsymbol{\omega}^\top \mathbf{x} + b)}\right]^2} \mathbf{x} \\ \frac{\partial^2 y}{\partial \boldsymbol{\omega} \partial \boldsymbol{\omega}^\top} &= \frac{\partial}{\partial \boldsymbol{\omega}^\top} \frac{\partial y}{\partial \boldsymbol{\omega}} \\ &= \frac{\partial}{\partial \boldsymbol{\omega}^\top} \frac{e^{-(\boldsymbol{\omega}^\top \mathbf{x} + b)}}{\left[1 + e^{-(\boldsymbol{\omega}^\top \mathbf{x} + b)}\right]^2} \mathbf{x} \\ &= \frac{e^{-(\boldsymbol{\omega}^\top \mathbf{x} + b)} \left[1 - e^{-(\boldsymbol{\omega}^\top \mathbf{x} + b)}\right]}{\left[1 + e^{-(\boldsymbol{\omega}^\top \mathbf{x} + b)}\right]^3} \mathbf{x} \mathbf{x}^\top \\ &= y(1 - y)(1 - 2y) \mathbf{x} \mathbf{x}^\top \end{aligned}$$

矩阵 $\mathbf{x} \mathbf{x}^\top$ 半正定, 而 $y(1 - y)(1 - 2y) < 0$ (as $y \in (\frac{1}{2}, 1)$), 其 Hessian 矩阵不总非负, 即 y 是非凸的。

$$\begin{aligned} \frac{\partial l}{\partial \boldsymbol{\beta}} &= \sum_{i=1}^m \left(-y_i \hat{\mathbf{x}}_i + \frac{e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i}}{1 + e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i}} \hat{\mathbf{x}}_i \right) \\ \frac{\partial^2 l}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^\top} &= \frac{\partial}{\partial \boldsymbol{\beta}^\top} \frac{\partial l}{\partial \boldsymbol{\beta}} \\ &= \frac{\partial}{\partial \boldsymbol{\beta}^\top} \sum_{i=1}^m \left(-y_i \hat{\mathbf{x}}_i + \frac{e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i}}{1 + e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i}} \hat{\mathbf{x}}_i \right) \\ &= \sum_{i=1}^m \frac{e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i}}{(1 + e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i})^2} \hat{\mathbf{x}}_i \hat{\mathbf{x}}_i^\top \end{aligned}$$

矩阵 $\hat{\mathbf{x}}_i \hat{\mathbf{x}}_i^\top$ 半正定, 而 $\frac{e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i}}{(1 + e^{\boldsymbol{\beta}^\top \hat{\mathbf{x}}_i})^2} \hat{\mathbf{x}}_i \hat{\mathbf{x}}_i^\top > 0$, 所以其 Hessian 矩阵半正定, 即 $l(\boldsymbol{\beta})$ 是凸的。

习题 3.7

设类别 i 的 ECOC 码为 r_i , 定义 $d(r_i, r_j)$ 为其海明距离 (编码不同的位数)。最大化的目标为

$$l = \prod_{1 \leq i < j \leq 4} d(r_i, r_j) + \sum_{1 \leq i < j \leq 4} d(r_i, r_j)$$

编写 C 代码程序，搜索得出解为

$$C_1 = 000000000 \quad C_2 = 000111111 \quad C_3 = 111000111 \quad C_4 = 111111000$$

其 $L = 46692$ 。

作业 3.3

多分类情形下的 $\mathbf{S}_b = \sum_{i=1}^N m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^\top$ 。

$$\mathbf{S}_b = [(\boldsymbol{\mu}_1 - \boldsymbol{\mu}), (\boldsymbol{\mu}_2 - \boldsymbol{\mu}), \dots, (\boldsymbol{\mu}_N - \boldsymbol{\mu})] \begin{pmatrix} m_1 & 0 & 0 \\ 0 & \dots & 0 \\ 0 & 0 & m_N \end{pmatrix} \begin{pmatrix} (\boldsymbol{\mu}_1 - \boldsymbol{\mu})^\top \\ \dots \\ (\boldsymbol{\mu}_N - \boldsymbol{\mu})^\top \end{pmatrix}$$

记 $\mathbf{M} = \text{diag}(m_1, m_2, \dots, m_N)$, $\mathbf{A} = [(\boldsymbol{\mu}_1 - \boldsymbol{\mu}), (\boldsymbol{\mu}_2 - \boldsymbol{\mu}), \dots, (\boldsymbol{\mu}_N - \boldsymbol{\mu})]^\top$, 则

$$\begin{aligned} \text{rank } \mathbf{S}_b &= \text{rank } \mathbf{A}^\top \mathbf{M} \mathbf{A} \\ &= \text{rank } \mathbf{A}^\top \mathbf{M}^{\frac{1}{2}} \mathbf{M}^{\frac{1}{2}} \mathbf{A} \\ &= \text{rank } \left(\mathbf{A}^\top \mathbf{M}^{\frac{1}{2}} \right) \left(\mathbf{A}^\top \mathbf{M}^{\frac{1}{2}} \right)^\top \\ &= \text{rank } \left(\mathbf{A}^\top \mathbf{M}^{\frac{1}{2}} \right) \\ &= \text{rank } \mathbf{A}^\top \end{aligned}$$

因为 $\sum_{i=1}^N m_i \boldsymbol{\mu}_i = \left(\sum_{i=1}^N m_i \right) \boldsymbol{\mu}$, 即 $\sum_{i=1}^N m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu}) = \mathbf{0}$, 所以 $\text{rank } \mathbf{A}^\top \leq N - 1$ 。

作业 3.4

式 3.44 是 $\max_{\mathbf{W}} \frac{\text{tr}(\mathbf{W}^\top \mathbf{S}_b \mathbf{W})}{\text{tr}(\mathbf{W}^\top \mathbf{S}_w \mathbf{W})}$, 如果 \mathbf{W} 是一个解, 那么 $\alpha \mathbf{W}, \alpha \in \mathbb{R}$ 也是一个解, 于是可固定 $\text{tr}(\mathbf{W}^\top \mathbf{S}_w \mathbf{W}) = 1$, 求解 $-\text{tr}(\mathbf{W}^\top \mathbf{S}_b \mathbf{W})$ 的最小值。

由拉格朗日乘子法, 定义拉格朗日函数

$$L(\mathbf{W}, \lambda) = -\text{tr}(\mathbf{W}^\top \mathbf{S}_b \mathbf{W}) + \lambda (\text{tr}(\mathbf{W}^\top \mathbf{S}_w \mathbf{W}) - 1).$$

对上式关于 \mathbf{W} 求偏导得

$$\begin{aligned} \frac{\partial L(\mathbf{W}, \lambda)}{\partial \mathbf{W}} &= -\frac{\partial (\text{tr}(\mathbf{W}^\top \mathbf{S}_b \mathbf{W}))}{\partial \mathbf{W}} + \lambda \frac{\partial (\text{tr}(\mathbf{W}^\top \mathbf{S}_w \mathbf{W}) - 1)}{\partial \mathbf{W}} \\ &= -(\mathbf{S}_b + \mathbf{S}_b^\top) \mathbf{W} + \lambda (\mathbf{S}_w + \mathbf{S}_w^\top) \mathbf{W} \\ &= -2\mathbf{S}_b \mathbf{W} + 2\lambda \mathbf{S}_w \mathbf{W} \end{aligned}$$

令 $L(\mathbf{W}, \lambda) = 0$ 可得 $\mathbf{S}_b \mathbf{W} = \lambda \mathbf{S}_w \mathbf{W}$ 。

作业 3.5

对称性:

$$\begin{aligned}(\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top)^\top &= (\mathbf{X}^\top)^\top ((\mathbf{X}^\top \mathbf{X})^{-1})^\top \mathbf{X}^\top \\&= (\mathbf{X}^\top)^\top ((\mathbf{X}^\top \mathbf{X})^\top)^{-1} \mathbf{X}^\top \\&= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top\end{aligned}$$

幂等性:

$$\begin{aligned}(\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top)^2 &= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \\&= \mathbf{X} \mathbf{I} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \\&= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top\end{aligned}$$

所以矩阵 $\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 是投影矩阵。

将特征矩阵 \mathbf{X} 看作是一个由 d 个 n 维列向量组成的向量组。假设 $d < n$ 且所有列向量都线性无关，那 \mathbf{X} 张成的空间是 d 维度空间。真实值 \mathbf{y} 是一个 n 维空间中的 $n \times 1$ 向量。线性回归就是在 \mathbf{X} 张成的 d 维空间中，寻找 n 维空间中 \mathbf{y} 的投影，也就是一种降维的操作。