

IML 第四次作业

习题 8.2

损失函数 $\ell(-f(x)H(x)) = \ell(-H(x))P(f(x) = 1|x) + \ell(H(x))P(f(x) = -1|x)$

当 $P(f(x) = 1|x) > P(f(x) = -1|x)$ 时, 要使 ℓ 最小, 必须 $\ell(-H(x)) < \ell(H(x))$, 若 ℓ 关于 $H(x)$ 在 $[-\infty, \delta]$ 上递减, 则 ℓ 关于 $-H(x)$ 在 $[-\delta, \infty]$ 上递增, 则 $\ell(-H(x)) < \ell(H(x)) \Rightarrow \ell(-H(x)) < \ell(-(-H(x))) \Rightarrow -H(x) < H(x) \Rightarrow H(x) > 0$, 这与 $P(f(x) = 1|x) > P(f(x) = -1|x)$ 一致。

当 $P(f(x) = -1|x) > P(f(x) = 1|x)$ 时, 要使 ℓ 最小, 必须 $\ell(-H(x)) < \ell(H(x))$, 若 ℓ 关于 $H(x)$ 在 $[-\infty, \delta]$ 上递减, 则 $\ell(-H(x)) < \ell(H(x)) \Rightarrow -H(x) > H(x) \Rightarrow H(x) < 0$, 这与 $P(f(x) = -1|x) > P(f(x) = 1|x)$ 一致。

所以当 ℓ 最小化时, 分类错误率也最小化, 说明 ℓ 是分类任务原本 0/1 损失函数的一致替代损失函数。

以下是按照习题课讲义的修改:

$$\begin{aligned} L(H | D) &= \mathbb{E}_{\mathbf{x}, y}[\ell(-yH(\mathbf{x}))] \\ &= \mathbb{E}_{\mathbf{x}, y}[\mathbb{I}(y = 1)\ell(-H(\mathbf{x})) + \mathbb{I}(y = -1)\ell(H(\mathbf{x}))] \\ &= \mathbb{E}_{\mathbf{x}}[\mathbb{E}_y[\mathbb{I}(y = 1)\ell(-H(\mathbf{x})) + \mathbb{I}(y = -1)\ell(H(\mathbf{x}))]] \\ &= \mathbb{E}_{\mathbf{x}}[P(y = 1 | \mathbf{x})\ell(-H(\mathbf{x})) + P(y = -1 | \mathbf{x})\ell(H(\mathbf{x}))] \\ &= \int_{\mathbf{x}} P(\mathbf{x})[P(y = 1 | \mathbf{x})\ell(-H(\mathbf{x})) + P(y = -1 | \mathbf{x})\ell(H(\mathbf{x}))] \end{aligned}$$

因此

$$\frac{\partial L(H | D)}{\partial H(\mathbf{x})} = P(\mathbf{x})(-P(y = 1 | \mathbf{x})\ell(-H(\mathbf{x})) + P(y = -1 | \mathbf{x})\ell(H(\mathbf{x}))) = 0$$

从而可得

$$P(y = 1 | \mathbf{x})\ell(-H(\mathbf{x})) = P(y = -1 | \mathbf{x})\ell(H(\mathbf{x}))$$

若 $P(y = 1 | \mathbf{x}) > P(y = -1 | \mathbf{x})$, 则有 $\ell(-H(\mathbf{x})) < \ell(H(\mathbf{x}))$ 由于单调性可知 $-H(\mathbf{x}) < H(\mathbf{x})$, 从而 $\text{sign}(H(\mathbf{x})) = 1$.

习题 8.8

MultiBoosting 优点: 有效降低误差和方差。缺点: 训练成本和预测成本高。

Iterative Bagging 优点: 降低误差。缺点: 增大方差。由于 Bagging 本身就是一种降低方差的算法, 所以 Iterative Bagging 相当于 Bagging 与单分类器的折中。

作业 9.1

假设取二维向量 $e_1 = (1,0), e_2 = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}), e_3 = (0,1)$, 则

$$D_1(e_1, e_2) = 1 - \frac{1}{\sqrt{2}}$$

$$D_1(e_2, e_3) = 1 - \frac{1}{\sqrt{2}}$$

$$D_1(e_1, e_3) = 1$$

但是 $D_1(e_1, e_2) + D_1(e_2, e_3) < D_1(e_1, e_3)$, 说明 D_1 (余弦距离) 不具有传递性。
任取三个不同的单位向量 x, y, z , 即余弦夹角函数为 D_2 , 则

$$\theta_1 := D_2(x, y) = \arccos \left(\frac{x^T y}{|x||y|} \right) = \arccos(x^T y)$$

$$\theta_2 := D_2(y, z) = \arccos \left(\frac{y^T z}{|y||z|} \right) = \arccos(y^T z)$$

$$\theta_3 := D_2(x, z) = \arccos \left(\frac{x^T z}{|x||z|} \right) = \arccos(x^T z)$$

注意到 $A = (x, y, z)^T (x, y, z) \geq 0$, 所以其行列式

$$\det(A) = 1 + 2(x^T y)(y^T z)(z^T x) - (x^T y)^2 - (y^T z)^2 - (x^T z)^2 \geq 0$$

即

$$\begin{aligned} 1 + 2 \cos \theta_1 \cos \theta_2 \cos \theta_3 - \cos^2 \theta_1 - \cos^2 \theta_2 - \cos^2 \theta_3 &\geq 0 \\ \Rightarrow (\cos \theta_1 \cos \theta_2 - \cos \theta_3)^2 &\leq (1 - \cos^2 \theta_1)(1 - \cos^2 \theta_2) \\ \Rightarrow \sin^2 \theta_1 \sin^2 \theta_2 &\geq (\cos \theta_1 \cos \theta_2 - \cos \theta_3)^2 \\ \Rightarrow \sin \theta_1 \sin \theta_2 &\geq |\cos \theta_1 \cos \theta_2 - \cos \theta_3| \geq \cos \theta_1 \cos \theta_2 - \cos \theta_3 \\ \Rightarrow \cos \theta_3 &\geq \cos \theta_1 \cos \theta_2 - \sin \theta_1 \sin \theta_2 \\ \Rightarrow \cos \theta_3 &\geq \cos(\theta_1 + \theta_2) \end{aligned}$$

若 $\theta_1 + \theta_2 \leq \pi$, 因为 $y = \cos x$ 在 $[0, \pi]$ 单调递减, 所以 $\theta_3 \leq \theta_1 + \theta_2$; 若 $\pi < \theta_1 + \theta_2 \leq 2\pi$, 因为 $\theta_3 < \pi$, 显然 $\theta_3 \leq \theta_1 + \theta_2$ 也成立, 所以传递性成立。

作业 9.2

损失函数 $E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2$, 则

$$\frac{\partial E}{\partial \mu_i} = 2 \sum_{x \in C_i} (x - \mu_i) = 0 \Rightarrow \mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x = \mu'_i$$

说明 μ'_i 是损失函数的极值点, 说明每次更新中心点为均值向量时, 都会让 E 严格减小, 由 $E \geq 0$ 有界, 所以最后一定会收敛。

作业 9.3

首先样本 x_j 与各均值向量 μ_i 的距离 d_{ji} 要用新的度量 $dist(x, \mu_j)$ 重新计算。

其次对于损失函数 $E = \sum_{i=1}^k \sum_{x \in C_i} dist(x, \mu_i)$, 由 $\frac{\partial E}{\partial \mu_i} (i = 1, \dots, k)$ 给出每个 μ_i' 的更新公式, 即由 $\sum_{x \in C_i} dist'(x, \mu_i) = 0$ 反解出的 μ_i 。