

IML 第六次作业

习题 7.4

欲防止 $p = \prod_{i=1}^d P(x_i | c)$ 计算时出现下溢，可以在计算时取对数，即计算

$$\log p = \sum_{i=1}^d \log P(x_i | c)$$

此时又可能发生上溢，可以在计算每一个 $\log P(x_i | c)$ 时，先除以 d ，随后再相加。这样在实践中可减少溢出的出现，即使出现了，也容易定位溢出步骤。

习题 7.5

最小化分类错误率的贝叶斯最优分类器为

$$h^*(x) = \arg \max_{c \in \mathcal{Y}} P(c | x) = \arg \max_{c \in \mathcal{Y}} P(x | c) P(c)$$

数据满足高斯分布时，有

$$\begin{aligned} h^*(x) &= \arg \max_{c \in \mathcal{Y}} \left\{ \log \left[\frac{1}{\sqrt{(2\pi)^n \det(\Sigma)}} e^{-\frac{1}{2}(x - \mu_c)^\top \Sigma^{-1}(x - \mu_c)} \right] + \log P(c) \right\} \\ &= \arg \max_{c \in \mathcal{Y}} \left[-\frac{1}{2}(x - \mu_c)^\top \Sigma^{-1}(x - \mu_c) + \log P(c) \right] \\ &= \arg \max_{c \in \mathcal{Y}} \left[x^\top \Sigma^{-1} \mu_c - \frac{1}{2} \mu_c^\top \Sigma^{-1} \mu_c + \log P(c) \right] \end{aligned}$$

记

$$f(c) = x^\top \Sigma^{-1} \mu_c - \frac{1}{2} \mu_c^\top \Sigma^{-1} \mu_c + \log P(c)$$

则在二分类任务中，贝叶斯决策边界为

$$g(x) = f(1) - f(0) = x^\top \Sigma^{-1}(\mu_1 - \mu_0) - \frac{1}{2}(\mu_1 + \mu_0)^\top \Sigma^{-1}(\mu_1 - \mu_0) + \log \frac{P(1)}{P(0)}$$

对于线性判别分析，参考书 3.39 式，可得投影界面为

$$w = (\Sigma_0 + \Sigma_1)^{-1}(\mu_1 - \mu_0)$$

当两类方差相同时，可化为

$$w = \frac{1}{2} \Sigma^{-1}(\mu_1 - \mu_0)$$

两类在投影面连线的中点为

$$\frac{1}{2}(\mu_1 + \mu_0)^\top w = \frac{1}{4}(\mu_1 + \mu_0)^\top \Sigma^{-1}(\mu_1 - \mu_0)$$

则线性判别分析的决策边界为

$$\tilde{g}(x) = x^\top \Sigma^{-1}(\mu_1 - \mu_0) - \frac{1}{2}(\mu_1 + \mu_0)^\top \Sigma^{-1}(\mu_1 - \mu_0)$$

因为假设同先验，所以 $\log \frac{P(1)}{P(0)} = 0$ ，所以 $g(x) = \tilde{g}(x)$ ，证毕。

作业 7.3

欲证明收敛，即证明 EM 算法每次迭代得到的 Θ^t 满足

$$P(X | \Theta^{t+1}) \geq P(X | \Theta^t)$$

由于 $\ln P(X | \Theta) = \ln P(X, Z | \Theta) - \ln P(Z | X, \Theta)$ ，等式两边同时求关于 $Z | X, \Theta^t$ 的期望，有

$$\mathbb{E}_{Z|X, \Theta^t}[\ln P(X | \Theta)] = \mathbb{E}_{Z|X, \Theta^t}[\ln P(X, Z | \Theta)] - \mathbb{E}_{Z|X, \Theta^t}[\ln P(Z | X, \Theta)]$$

因为 $\ln P(X | \Theta)$ 与 Z 无关，所以

$$\mathbb{E}_{Z|X, \Theta^t}[\ln P(X | \Theta)] = \int_Z P(Z | X, \Theta^t) \ln P(X | \Theta) dZ = \ln P(X | \Theta)$$

而 $\mathbb{E}_{Z|X, \Theta^t}[\ln P(X, Z | \Theta)] = Q(\Theta, \Theta^t)$ ，因为

$$\Theta^{t+1} = \arg \max_{\Theta} Q(\Theta, \Theta^t)$$

必然有

$$Q(\Theta^{t+1}, \Theta^t) \geq Q(\Theta, \Theta^t)$$

令 $\Theta = \Theta^t$ ，则

$$Q(\Theta^{t+1}, \Theta^t) \geq Q(\Theta^t, \Theta^t)$$

下面只需证

$$\mathbb{E}_{Z|X, \Theta^t}[\ln P(Z | X, \Theta^{t+1})] \leq \mathbb{E}_{Z|X, \Theta^t}[\ln P(Z | X, \Theta^t)]$$

即证

$$\mathbb{E}_{Z|X, \Theta^t} \left[\ln \frac{P(Z | X, \Theta^{t+1})}{P(Z | X, \Theta^t)} \right] = -D_{KL} [P(Z | X, \Theta^t) \| P(Z | X, \Theta^{t+1})] \leq 0$$

根据 KL 散度的性质知上式成立，所以 $\{P(X | \Theta^n)\}$ 单调递增有上界，收敛性得证。

作业 7.4

假设模型为 $\lambda = [A, B, \pi]$ ，则

$$P(x_{n+1} | x_1, \dots, x_n) = \frac{P(x_{n+1}, x_n | x_1, \dots, x_{n-1})}{P(x_n | x_1, \dots, x_{n-1})}$$

记 $P(n) = P(x_n | x_1, \dots, x_{n-1})$, $P(1) = P(x_1)$ ，则

$$P(x_{n+1}, x_n, \dots, x_1) = \prod_{i=1}^{n+1} P(i)$$

又因为已知

$$P(x_{n+1}, x_n, \dots, x_1) = \sum_{y_t} \alpha(y_t) \beta(y_t)$$

所以只需要利用上述两式不断递推，即可求出 $P(n+1)$ 。

作业 14.1

$$(1) p(D, \mu, \lambda) = p(\mu, \lambda) p(D|\mu, \lambda) = p(\mu, \lambda) \prod_{i=1}^m p(x_i|\mu, \lambda) = \frac{1}{\sqrt{2\pi(\kappa_0\lambda)^{-1}}} \cdot \exp\left\{-\frac{1}{2(\kappa_0\lambda)^{-1}}(\mu - \mu_0)^2\right\} \cdot \frac{1}{\Gamma(a_0)} b_0^{a_0} \lambda^{a_0-1} \exp\{-b_0\lambda\} \cdot \left(\frac{\lambda}{2\pi}\right)^{\frac{m}{2}} \exp\left\{-\frac{\lambda}{2} \sum_{i=1}^m (x_i - \mu)^2\right\}$$

(2) 由变分推断的推导知:

$$\sum_{i=1}^m \log P(x_i) = \log P(x) \geq \mathbb{E}[\log P(Z, x)] - \mathbb{E}[\log q(Z)]$$

所以证据下界为 $\mathbb{E}[\log P(Z, x)] - \mathbb{E}[\log q(Z)] = \mathbb{E}_q[\log P(\lambda)] + \mathbb{E}_q[\log P(\mu|\lambda)] + \mathbb{E}_q[\log P(x|\mu, \lambda)] - \mathbb{E}_q[\log q(\lambda)] - \mathbb{E}_q[\log q(\mu)]$, 证明如下:

变分推断的目标是

$$q^*(Z) = \arg \min_{q(Z)} D_{KL}[q(Z)||P(Z|x)]$$

其中

$$D_{KL}[q(Z)||p(Z|x)] = \mathbb{E}[\log q(Z)] - \mathbb{E}[\log P(Z, x)] + \log P(x)$$

由于 $D_{KL} \geq 0$, 所以

$$\log P(x) \geq \mathbb{E}[\log P(Z, x)] - \mathbb{E}[\log q(Z)]$$

不等号右边就是下界。

(3) 通过最大化 L 来最小化 $KL(q||P)$, 偏导

$$\frac{\partial L}{\partial q_\lambda(\mu)} = \mathbb{E}_\lambda[\log P(\mu|\lambda)] + \mathbb{E}_\lambda[\log P(D|\mu, \lambda)] - \log q(\mu) = 0$$

则

$$\begin{aligned} \log q^*(\mu) &= -\frac{\mathbb{E}\lambda\kappa_0}{2}(\mu - \mu_0)^2 - \frac{\mathbb{E}\lambda}{2} \sum_{i=1}^m (x_i - \mu)^2 \\ &= -\frac{\mathbb{E}\lambda}{2} \left[(\kappa_0 + m)\mu^2 + \sum_{i=1}^m x_i^2 - 2\mu(\kappa_0\mu_0 + m\bar{x}) \right] \\ &= -\frac{\mathbb{E}\lambda}{2} \left[(\kappa_0 + m) \left(\mu - \frac{\kappa_0\mu_0 + m\bar{x}}{\kappa_0 + m} \right)^2 + \sum_{i=1}^m x_i^2 - \frac{(\kappa_0\mu_0 + m\bar{x})^2}{\kappa_0 + m} \right] \end{aligned}$$

后两项不影响 $q(\mu)$ 的分布, 所以

$$q(\mu) \sim \mathcal{N}\left(\mu \mid \frac{\kappa_0\mu_0 + m\bar{x}}{\kappa_0 + m}, [(\kappa_0 + m)\mathbb{E}\lambda]^{-1}\right)$$

又

$$\frac{\partial L}{\partial q_\mu(\lambda)} = \mathbb{E}_\mu[\log P(D|\lambda, \mu)] + \mathbb{E}[\log(\mu|\lambda)] + \mathbb{E}_\mu[\log P(\lambda)] - \log q(\lambda) = 0$$

所以

$$\begin{aligned}\log q^*(\lambda) &= -\frac{\lambda}{2} \mathbb{E}_\mu[\kappa_0(\mu - \mu_0)^2 + \sum_{i=1}^m (x_i - \mu)^2] + (a_0 - 1) \log \lambda - b_0 \lambda + \frac{m+1}{2} \log \lambda \\ &= (a_0 + \frac{m-1}{2}) \log \lambda - (b_0 + \frac{1}{2} \mathbb{E}_\mu[\kappa_0(\mu - \mu_0)^2 + \sum_{i=1}^m (x_i - \mu)^2]) \lambda\end{aligned}$$

即

$$q^*(\lambda) \sim \text{Gam}(\lambda | a_0 + \frac{m-1}{2}, b_0 + \frac{1}{2} \mathbb{E}_\mu[\kappa_0(\mu - \mu_0)^2 + \sum_{i=1}^m (x_i - \mu)^2])$$

所以 $q^*(\mu, \lambda) \sim \mathcal{N}(\mu | \frac{\kappa_0 \mu_0 + m \bar{x}}{\kappa_0 + m}, [(\kappa_0 + m) \mathbb{E} \lambda]^{-1}) \text{Gam}(\lambda | a_0 + \frac{m-1}{2}, b_0 + \frac{1}{2} \mathbb{E}_\mu[\kappa_0(\mu - \mu_0)^2 + \sum_{i=1}^m (x_i - \mu)^2])$ 。

在无先验的情况下 $\mu_0 = a_0 = b_0 = \kappa_0 = 0$, 且

$$\begin{aligned}\mathbb{E} \lambda &= \frac{a_0 + \frac{m-1}{2}}{b_0 + \frac{1}{2} \mathbb{E}_\mu[\kappa_0(\mu - \mu_0)^2 + \sum_{i=1}^m (x_i - \mu)^2]} \\ \mathbb{E} \mu^2 &= \bar{x}^2 + \frac{1}{m \mathbb{E} \lambda} \quad \mathbb{E} \mu = \mu_m = \bar{x}\end{aligned}$$

联立解得

$$\mathbb{E} \lambda = \frac{1}{\text{Var} X}$$

代回含 $\mathbb{E} \lambda$ 的式子得到 λ^*, b^* , 即可得

$$P(\mu, \lambda | D) \sim \mathcal{N}(\mu | \bar{x}^2, \lambda^*) \text{Gam}(\lambda | \frac{m-1}{2}, b^*)$$

作业 14.2

条件随机场的预测问题是给定条件随机场 $P(Y | X)$ 和输入序列 (观测序列) x , 求条件概率最大的输出序列 (标记序列) y^* , 即对观测序列进行标注。

由 $P_w(y|x) = \frac{\exp(w \cdot F(y, x))}{Z_w(x)}$ 可得:

$$\begin{aligned}y^* &= \arg \max_y P_w(y | x) \\ &= \arg \max_y \frac{\exp(w \cdot F(y, x))}{Z_w(x)} \\ &= \arg \max_y \exp(w \cdot F(y, x)) \\ &= \arg \max_y (w \cdot F(y, x))\end{aligned}$$

于是, 问题转化为求非规范化概率最大的最优路径问题

$$\max_y (w \cdot F(y, x))$$

这里, 路径表示标记序列。其中,

$$\begin{aligned} w &= (w_1, w_2, \dots, w_K)^\top \\ F(y, x) &= (f_1(y, x), f_2(y, x), \dots, f_K(y, x))^\top \\ f_k(y, x) &= \sum_{i=1}^n f_k(y_{i-1}, y_i, x, i), \quad k = 1, 2, \dots, K \end{aligned}$$

为了求解最优路径, 目标函数写成如下形式:

$$\max_y \sum_{i=1}^n w \cdot F_i(y_{i-1}, y_i, x)$$

其中局部特征向量

$$F_i(y_{i-1}, y_i, x) = (f_1(y_{i-1}, y_i, x, i), f_2(y_{i-1}, y_i, x, i), \dots, f_K(y_{i-1}, y_i, x, i))^\top$$

下面是用维特比算法解决此问题的步骤。

首先求出位置 1 的各个标记 $j = 1, 2, \dots, m$ 的非规范化概率

$$\delta_1(j) = w \cdot F_1(y_0 = \text{start}, y_1 = j, x), \quad j = 1, 2, \dots, m$$

由递推公式, 求出到位置 i 的各个标记 $l = 1, 2, \dots, m$ 的非规范化概率的最大值, 同时记录非规范化概率最大值的路径

$$\delta_i(l) = \max_{1 \leq j \leq m} \{\delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x)\}, \quad l = 1, 2, \dots, m$$

$$\Psi_i(l) = \arg \max_{1 \leq j \leq m} \{\delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x)\}, \quad l = 1, 2, \dots, m$$

直到 $i = n$ 时终止, 这时求得非规范化概率的最大值为

$$\max_y (w \cdot F(y, x)) = \max_{1 \leq j \leq m} \delta_n(j)$$

及最优路径的终点

$$y_n^* = \arg \max_{1 \leq j \leq m} \delta_n(j)$$

由此最优路径终点返回

$$y_i^* = \Psi_{i+1}(y_{i+1}^*), \quad i = n-1, n-2, \dots, 1$$

求得最优路径 $y^* = (y_1^*, y_2^*, \dots, y_n^*)^\top$ 。